

Projeto EDA2: Agrupamento de Notícias

Arquitetura Integrada, Decisões Técnicas e Implementação Otimizada

Integrantes do Grupo

Giovani Coelho | Artur Galdino | João Leles | Davi Oliveira | Fábio
Vieira

Descrição do Problema

O Desafio: Agrupar automaticamente um grande volume de notícias em editorias consistentes (ex: política, esporte, economia) sem o uso de rótulos prévios ou categorização humana.

Efeito Encadeamento: Existe o risco constante de "notícias ponte" fundirem acidentalmente temas distintos através de uma conexão fraca (ex: política se misturando com esporte).

Explosão de Memória: Ao calcular a similaridade entre todas as notícias, um grafo completo consumiria rapidamente toda a memória do sistema (Grafo Denso).



Modelagem do Grafo Base

Implementação "Zero-Libs"

Nossa classe de Grafo foi construída inteiramente do zero, utilizando um dicionário nativo do Python na forma de Lista de Adjacência. Cada **Nó** representa uma notícia isolada, e cada **Aresta** representa a métrica de distância semântica processada externamente.

Filtro de Densidade de Memória

Para evitar a criação de um grafo denso, a função de adicionar arestas inclui um ponto de corte: similaridades menores que 0.20 são imediatamente bloqueadas. Essa trava transforma a rede em um **Grafo Esparso**, o que garante matematicamente que operações de travessia rodem no tempo ótimo de $O(V + E)$

Descrição da Solução

1. Limpeza Textual (PLN)

O primeiro passo consiste na remoção de pontuações e *stop words*, focando os algoritmos unicamente no valor semântico real das notícias processadas.


2. Similaridade de Jaccard

As notícias são comparadas sistematicamente (duas a duas) para estabelecer uma métrica exata de proximidade temática.


3. Conversão de Distância

Como o Algoritmo de Kruskal requer a localização dos caminhos mínimos para conectar a rede, nós utilizamos a fórmula

$$\text{Distância} = 1 - \text{Similaridade}$$




Implementação Otimizada e Estruturas Auxiliares




Arquitetura Limpa

O ambiente foi dividido em src/ para o núcleo de grafos e PLN, data/ para centralização da massa JSON, e test/ para os scripts de validação.



Union-Find Extremo

Integrado ao algoritmo de Kruskal com *Compressão de Caminho*, impedindo o surgimento de laços na MST em um tempo quase constante $O(\alpha(N))$



Hash $O(1)$

Desenvolvimento de um tradutor robusto entre Títulos e IDs Numéricos em dicionários nativos, alcançando busca imediata em $O(1)$

Exemplos de Entrada e Saída (Validação)

Massa de Dados (Entrada JSON)

Arquivo noticias.json carregado com um volume controlado de ~60 notícias, englobando grandes temas independentes.

```
> [1/4] Processando textos...  
> Total de combinações: 1770  
> [2/4] Montando Grafo (Corte 0.80)  
> Arestas válidas: 554
```

Clusters Gerados (Saída de Kruskal)

O rompimento das arestas mais pesadas destrói a árvore MST originando agrupamentos isolados perfeitamente corretos.

```
> Tópico 1 (Contém 19 notícias):  
IDs: [1, 2, 3, 4, 5... 19]  
  
> Tópico 2 (Contém 21 notícias):  
IDs: [39, 40, 41... 60]  
  
> Tópico 3 (Contém 20 notícias):  
IDs: [20, 21, 22... 58]
```


Exemplos de Entrada e Saída (Validação)

```
Iniciando auditoria analítica dos dados...
```

RELATÓRIO DE ACURÁCIA DE CLUSTERIZAÇÃO

```
Cluster 1 classificado como: ESPORTES
```

```
-> Notícias alvo corretas capturadas: 19 de 19
```

```
Cluster 2 classificado como: TECNOLOGIA
```

```
-> Notícias alvo corretas capturadas: 19 de 19
```

```
-> Nós Ponte absorvidos por gravidade semântica: {59, 60}
```

```
Cluster 3 classificado como: ECONOMIA
```

```
-> Notícias alvo corretas capturadas: 19 de 19
```

```
-> Nós Ponte absorvidos por gravidade semântica: {58}
```

```
giovani-coelho@giovani-coelho-Inspiron-5565: ~/documentos/Projeto-LDA23 $ python3 main.py
[1/4] Processando textos e calculando distâncias de Jaccard...
      Total de combinações analisadas: 1770
[2/4] Montando o Grafo e aplicando Filtro de Densidade (Corte de 0.80)...
      Arestas válidas no grafo após o filtro: 554
[3/4] Executando Kruskal (Union-Find) para formar 3 tópicos...
```

===== 🔗 RESULTADO DO AGRUPAMENTO (COMUNIDADES ENCONTRADAS) =====

```
Tópico 1 (Contém 19 notícias):
```

```
IDs: [1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19]
```

```
Tópico 2 (Contém 21 notícias):
```

```
IDs: [39, 40, 41, 42, 43, 44, 45, 46, 47, 48, 49, 50, 51, 52, 53, 54, 55, 56, 57, 59, 60]
```

```
Tópico 3 (Contém 20 notícias):
```

```
IDs: [20, 21, 22, 23, 24, 25, 26, 27, 28, 29, 30, 31, 32, 33, 34, 35, 36, 37, 38, 58]
```

```
=====
[4/4] Alimentando Tabela Hash para busca 0(1)...
```

===== 🔍 TESTE DE BUSCA 0(1) NA TABELA HASH =====

```
Sucesso! O título 'Mercado financeiro cai com decisão do banco sobre juros' corresponde ao ID 20.
```

Análise dos Resultados Obtidos

1. Abordagem Ingênua

- **Grafo:** Rede densa e completa, causando travamentos e risco de "Out of Memory".
- **Ciclos (MST):** Detecção via Algoritmo DFS com alto custo de processamento $O(V)$
- **Busca de Títulos:** Varredura de matriz linear com complexidade de tempo $O(N)$
- **Editorias:** Vulnerável ao "Efeito Encadeamento", unindo temas acidentalmente.

2. Nossa Otimização Aplicada

- **Grafo:** Transformado em rede Esparsa operando no tempo ótimo de $O(V + E)$
- **Ciclos (MST):** Integrado ao Union-Find Avançado operando em tempo quase constante.
- **Busca de Títulos:** Tabela Hash Dinâmica com resolução e tradução imediata $O(1)$
- **Editorias:** Isolamento e separação perfeitos após o corte das Arestas Superiores.

O Uso de LLM no Desenvolvimento

- **Geração da Massa Sintética de Testes:** Nós utilizamos inteligência artificial para criar inteiramente o arquivo `noticias.json`, desenvolvendo um escopo de dados altamente controlado para validar com exatidão a divisão teórica dos temas.
- **Revisão Lógica e Depuração:** O modelo foi consultado para cancelar a estrutura matemática implementada nas funções de *Compressão de Caminho* do Union-Find, assegurando a validade assintótica.
- **Defesa Arquitetural Teórica:** Emprego estratégico da IA para auxiliar na fundamentação do discurso lógico, documentando de forma clara as razões das escolhas algorítmicas frente às alternativas menos performáticas.



Dúvidas?

Fiquem à vontade para questionar nosso código, lógica estrutural e as decisões matemáticas adotadas durante o projeto.

Projeto: **Tópicos de Notícias**
Matéria: **Estrutura de Dados 2**